


Análisis Exploratorio de Datos

EDA · Exploratory Data Analysis

*Escuchar lo que los datos tienen que decir
antes de decidir cualquier modelo.*



Qué vamos a ver

Cuatro bloques, de la definición a la práctica

01 Fundamentos

Qué es el EDA, de dónde viene y por qué es la fase que más decisiones condiciona.

02 Primeros pasos

Tipos de variables, primer contacto con el dataset y estadística descriptiva.

03 Técnicas de análisis

Univariado, bivariado y multivariado: qué gráfico usar en cada caso.

04 Calidad y práctica

Faltantes, outliers, herramientas, checklist y errores frecuentes.

¿Qué es el EDA?

Definición

El Análisis Exploratorio de Datos es el proceso de examinar un conjunto de datos —con estadística descriptiva y visualización— para entender su estructura, evaluar su calidad y descubrir patrones, antes de formular conclusiones o entrenar modelos.



Es descriptivo, no concluyente

Describe lo que hay en los datos; no demuestra hipótesis ni establece causas.



Es iterativo

Cada gráfico responde una pregunta y abre dos nuevas. Se vuelve atrás constantemente.



Es visual antes que numérico

Un resumen numérico puede ocultar lo que un gráfico revela en dos segundos.

¿Por qué es la fase que más pesa?

Lo que no se detecta aquí se arrastra hasta la conclusión final

≈80%

del tiempo de un proyecto

Cifra ampliamente citada en la industria: la mayor parte del esfuerzo se va en obtener, limpiar y explorar datos, no en modelar.

1er

filtro de calidad

Duplicados, unidades mezcladas, fechas imposibles o categorías mal escritas solo aparecen si alguien mira los datos de cerca.

0

modelos que arreglan datos malos

Ningún algoritmo compensa un dataset que no se entendió. Garbage in, garbage out sigue vigente.



Un modelo con una métrica excelente puede estar aprendiendo de una fuga de información, de un duplicado masivo o de una columna que en producción no existirá. El EDA es donde eso se descubre.

Dónde encaja en el proyecto

El EDA no es un paso: es un punto al que se vuelve una y otra vez



Cada hallazgo del EDA suele mandarte de vuelta a limpiar algo, y cada limpieza cambia lo que ves. También se vuelve al EDA después de modelar, para entender por qué el modelo falla donde falla.

Los seis objetivos de un EDA

Si al terminar puedes responder a estas seis cosas, el EDA está hecho



Conocer la estructura

Cuántas filas y columnas, qué tipo tiene cada variable, qué representa una fila.



Detectar problemas de calidad

Nulos, duplicados, valores imposibles, categorías escritas de varias formas.



Identificar valores atípicos

Puntos extremos: ¿son errores de registro o casos reales e informativos?



Descubrir patrones y relaciones

Tendencias, agrupaciones, correlaciones y comportamientos por segmento.



Validar supuestos

Normalidad, escalas comparables, independencia: lo que exigen los modelos.



Generar hipótesis

Preguntas nuevas y bien fundadas que merecen contrastarse formalmente.

Tipos de variables

El tipo de variable decide qué estadístico y qué gráfico puedes usar

Cuantitativas (numéricas)

Discretas

Se cuentan, valores enteros. Nº de hijos, pedidos por día.

Continuas

Se miden, admiten decimales. Altura, precio, temperatura.

Cualitativas (categóricas)

Nominales

Categorías sin orden. Color, país

Ordinales

Categorías con orden. Nivel educativo

Cuidado con los disfraces numéricos

Un código postal, un DNI o un ID de cliente se guardan como números, pero no son cantidades: calcular su media no significa nada. Revisa siempre el significado, no solo el tipo que ha inferido pandas.

Primer contacto con el dataset

Cinco minutos de código que evitan horas de análisis mal orientado

```
import pandas as pd
df = pd.read_csv('datos.csv')

df.shape          # (filas, columnas)
df.head(10)       # primeras filas reales
df.dtypes         # tipo de cada columna
df.info()         # nulos y memoria
df.describe()     # resumen numérico
df.describe(include='object')

df.isna().sum()   # nulos por columna
df.duplicated().sum()
df['categoria'].value_counts()
df['categoria'].nunique()
```

● ¿De qué tamaño es?

Mil filas y un millón de filas no se analizan igual.

● ¿Qué es una fila?

Un cliente, una transacción, un día... Definirlo evita interpretaciones erróneas.

● ¿Los tipos son correctos?

Fechas leídas como texto y números leídos como object son el problema nº 1.

● ¿Cuánto falta y dónde?

Los nulos concentrados en pocas columnas o filas cambian la estrategia.

● ¿Hay duplicados?

Registros repetidos inflan frecuencias y sesgan cualquier promedio.

Medidas de tendencia central

Tres formas de responder a «¿cuál es el valor típico?»



Media

$$\bar{x} = \sum x_i / n$$

Promedio aritmético. Usa toda la información, pero un solo valor extremo la desplaza.



Mediana

Valor central (P50)

Deja el 50 % de los datos a cada lado.
Robusta frente a valores atípicos.



Moda

Valor más frecuente

La única aplicable a variables categóricas. Puede no ser única.

Medidas de dispersión

El valor típico no basta: hay que saber cuánto varían los datos a su alrededor

Rango

máx – mín. Muy simple y muy sensible a un único valor extremo.

Varianza (σ^2)

Media de las desviaciones al cuadrado. Sus unidades están al cuadrado.

Desviación típica (σ)


Raíz de la varianza. Vuelve a las unidades originales: es la más interpretable.

Rango intercuartílico (IQR)

$Q3 - Q1$. Recoge el 50 % central de los datos y es robusto a atípicos.

Anatomía de un boxplot

Un solo gráfico que resume mediana, dispersión, asimetría y atípicos.



Si la mediana no está centrada en la caja, la distribución es asimétrica: la cola larga marca hacia dónde se estira.

Análisis univariado

Una variable cada vez: ¿cómo se distribuye?

Variables numéricas


Histograma, densidad y boxplot. Observa: centro, dispersión, forma (simétrica o sesgada), número de picos y presencia de colas.

Variables categóricas

Gráfico de barras y tabla de frecuencias. Observa: categorías dominantes, categorías con muy pocos casos y errores de escritura que duplican niveles.

Qué preguntarse

¿Hay un pico o varios? Dos picos suelen indicar que en la misma columna conviven dos grupos distintos que conviene separar.



Distribución sesgada a la derecha: la cola se estira hacia los valores altos.

Análisis bivariado

Dos variables a la vez: ¿se mueven juntas?



Numérica + numérica

Diagrama de dispersión y coeficiente de correlación.

Numérica + categórica

Boxplot o violín por grupo; comparar medianas.

Categórica + categórica

Tabla de contingencia y barras agrupadas.



Correlación $\neq$ causalidad

Que dos variables suban a la vez no significa que una cause la otra: puede haber una tercera variable detrás, o pura coincidencia.

Análisis multivariado

Tres o más variables: relaciones que no se ven de dos en dos

Matriz de correlación

	Edad	Ingreso	Gasto	Compras	Antigüe.
Edad	1.00	0.42	0.18	-0.05	0.61
Ingreso	0.42	1.00	0.78	0.35	0.29
Gasto	0.18	0.78	1.00	0.66	0.12
Compras	-0.05	0.35	0.66	1.00	0.08
Antigüe.	0.61	0.29	0.12	0.08	1.00

Cuanto más intenso el color, más fuerte la relación. El naranja indica correlación negativa.

1

Mapa de calor de correlaciones

Vista rápida de todas las parejas numéricas a la vez.

2

Pairplot (matriz de dispersión)

Todos los scatter cruzados, con histogramas en la diagonal.

3

Color, tamaño y facetas

Añade una tercera o cuarta variable a un gráfico de dos ejes.


4

Reducción de dimensión (PCA)

Resume muchas variables en pocos ejes para ver la estructura global.

Valores faltantes

Antes de decidir qué hacer con ellos, pregúntate por qué faltan



Estrategias habituales

- Eliminar filas: solo si son pocas y no siguen un patrón.
- Eliminar la columna: si falta en una proporción muy alta.
- Imputar: media o mediana (numéricas), moda o categoría «Desconocido» (categóricas).
- Marcar: crear una columna indicadora de que el dato faltaba.


Valores atípicos (outliers)

Detectarlos es fácil; decidir qué hacer con ellos es el verdadero trabajo

Regla del rango intercuartílico

Es atípico todo valor fuera de $[Q1 - 1,5 \cdot IQR , Q3 + 1,5 \cdot IQR]$

Rango considerado normal



Cómo detectarlos

- Boxplot y regla del IQR
- Puntuación z: $|z| > 3$
- Percentiles extremos (1 % y 99 %)
- Métodos multivariantes (Isolation Forest)



Qué hacer con ellos

- Corregir, si es un error evidente de registro
- Conservar, si es un caso real e informativo
- Acotar (winsorizing) o transformar (log)
- Analizar aparte y documentar la decisión

Checklist para tu próximo EDA

Un orden de trabajo que funciona en casi cualquier dataset

1

Formula la pregunta que quieres responder antes de abrir los datos.

3

Mide nulos y duplicados; decide y documenta cómo tratarlos.

5

Cruza las variables clave contra la variable objetivo.

7

Localiza atípicos, entiende su origen y justifica tu decisión.

2

Carga y comprueba dimensiones, tipos y qué representa cada fila.

4

Analiza cada variable por separado: distribución, centro y dispersión.

6

Revisa correlaciones y busca redundancias entre predictores.

8

Escribe las conclusiones y las hipótesis que has generado.

Errores frecuentes

Los cinco tropiezos que más se repiten en un EDA de principiante

1

Explorar sin una pregunta

Producir cincuenta gráficos sin saber qué se busca genera ruido, no conocimiento.

2

Fiarse solo de los números

El cuarteto de Anscombe lo demuestra: sin gráficos, los resúmenes engañan.

3

Eliminar outliers por sistema

A veces el valor extremo es exactamente el fenómeno que hay que estudiar.

4

Imputar sin pensar

Rellenar todo con la media distorsiona la varianza y las relaciones entre variables.

5

Explorar con el conjunto de test

Mirar los datos de prueba filtra información y infla artificialmente los resultados.

Un buen EDA se reconoce porque cada decisión tomada sobre los datos está escrita y justificada.

Tres ideas que llevarse

1

El EDA describe, no concluye

Sirve para entender y generar hipótesis, no para demostrarlas.

2

Grafica siempre

Los estadísticos resumen; los gráficos revelan. Nunca renuncies a mirar.

3

Documenta cada decisión

Un análisis que no se puede reconstruir no vale como evidencia.

Para practicar

- Titanic — nulos y variables mixtas
- Iris — clásico y muy visual
- Palmer Penguins — alternativa moderna
- Ames Housing — muchas columnas
- Un CSV propio: datos reales de tu contexto

Ejercicio propuesto: elige un dataset, aplica el checklist completo y entrega un informe con tus tres hallazgos principales.