

Análisis Exploratorio de Datos (EDA) de Imágenes con TrashNet

Dataset

TrashNet contiene 2,527 imágenes de residuos clasificadas en seis categorías: glass, paper, cardboard, plastic, metal y trash. En la versión redimensionada de la fuente original las imágenes tienen una resolución de 512 × 384 píxeles.

Fuente original: Gary Thung y Mindy Yang, TrashNet (GitHub): <https://github.com/garythung/trashnet>

A. Comprensión y estructura del dataset

1. Explique brevemente cuál es el objetivo general del dataset TrashNet y qué tipo de problema de aprendizaje automático podría abordarse posteriormente con estos datos.
2. Inspeccione la estructura de carpetas del dataset e identifique las clases disponibles. ¿Cuántas categorías distintas existen y cuáles son?
3. Calcule el número total de imágenes presentes en el dataset. Compare el resultado con la cantidad reportada por la fuente original.
4. Calcule la cantidad de imágenes por clase y presente los resultados en una tabla ordenada de mayor a menor frecuencia.
5. Visualice la distribución de imágenes por clase mediante un gráfico de barras. ¿El dataset está balanceado? Justifique su respuesta.
6. Calcule el porcentaje que representa cada clase respecto del total. Determine la clase mayoritaria, la minoritaria y la razón de desbalance entre ambas.

B. Calidad, formato y metadatos de las imágenes

7. Verifique programáticamente que todas las imágenes puedan abrirse correctamente. ¿Existen archivos corruptos o ilegibles?
8. Identifique las extensiones o formatos de archivo presentes en el dataset y calcule su frecuencia.
9. Calcule el tamaño de cada archivo en kilobytes. Obtenga estadísticas descriptivas globales del tamaño de archivo y compárelas entre clases.
10. Extraiga el ancho y alto de todas las imágenes. Determine cuántas resoluciones diferentes existen y cuáles son las más frecuentes.
11. Calcule la relación de aspecto (ancho/alto) de cada imagen. ¿La relación de aspecto es uniforme o existen imágenes atípicas?
12. Identifique el modo o número de canales de las imágenes (por ejemplo, RGB, escala de grises). ¿Todas tienen la misma estructura de canales?

C. Inspección visual y análisis de color

13. Muestre una cuadrícula con varias imágenes aleatorias de cada clase. Describa visualmente qué características parecen diferenciar unas categorías de otras.
14. Calcule el valor medio de los canales R, G y B para cada imagen y obtenga posteriormente el promedio de estos valores por clase.
15. Compare mediante gráficos la distribución de la intensidad media de los canales R, G y B entre las seis clases. ¿Se observan diferencias apreciables?
16. Construya una imagen promedio para cada clase. ¿Qué información aporta una imagen promedio y qué patrones generales pueden observarse?
17. Convierta las imágenes a escala de grises y calcule el brillo medio de cada imagen. Obtenga estadísticas descriptivas del brillo para todo el dataset.
18. Compare la distribución del brillo entre clases mediante boxplots. ¿Qué clases presentan imágenes relativamente más claras u oscuras?
19. Identifique y visualice las cinco imágenes más oscuras y las cinco más claras del dataset según el brillo medio calculado.
20. Calcule una medida de contraste para cada imagen utilizando la desviación estándar de las intensidades en escala de grises.
21. Compare el contraste entre las distintas clases. Identifique las clases con mayor y menor contraste mediano.
22. Convierta las imágenes al espacio HSV y calcule la saturación media. Analice si determinadas clases presentan colores más intensos que otras.
23. Seleccione imágenes representativas de al menos tres clases y construya histogramas de intensidad para sus canales RGB. Explique cómo interpretar estos histogramas.

D. Complejidad visual, duplicados y outliers

24. Calcule una medida sencilla de complejidad visual basada en cambios o bordes de intensidad. Compare esta medida entre las clases.
25. Calcule la entropía de intensidad de cada imagen. ¿Qué representa esta métrica y qué clases muestran mayor entropía mediana?
26. Busque archivos exactamente duplicados utilizando un hash criptográfico (por ejemplo, MD5). ¿Existen imágenes con contenido binario idéntico?
27. Implemente un hash perceptual sencillo (average hash) para buscar imágenes visualmente idénticas o muy similares. Visualice algunos grupos candidatos si existen.
28. Utilice el método IQR sobre variables derivadas de las imágenes (brillo, contraste, saturación, entropía y complejidad visual) para identificar posibles outliers. ¿Cuántas imágenes son marcadas como atípicas?
29. Construya una matriz de correlación entre las características numéricas extraídas de las imágenes. Analice las relaciones más relevantes y explique por qué algunas características podrían estar asociadas.

E. Síntesis del EDA

30. A partir de todos los resultados obtenidos, redacte al menos cinco conclusiones del EDA y proponga decisiones de preprocesamiento que deberían considerarse antes de entrenar un modelo de clasificación de imágenes con TrashNet.