

Práctica EDA 1: Pasajeros del Titanic

1. Carga el archivo ``titanic.csv`` y realiza el primer contacto con el dataset. Reporta dimensiones, primeras filas, tipos de datos y define con tus palabras qué representa una fila.

Pista de trabajo: ``shape``, ``head()``, ``info()`` y ``dtypes``.

2. Clasifica las variables ``survived``, ``pclass``, ``sex``, ``age``, ``sibsp``, ``fare``, ``embarked``, ``deck`` y ``alone`` como cuantitativas o cualitativas; cuando corresponda, indica si son discretas/continuas o nominales/ordinales. Explica al menos dos “disfraces numéricos”.

Pista de trabajo: No clasifiques solo por el dtype de pandas; piensa en el significado.

3. Analiza los valores faltantes. Calcula cantidad y porcentaje de nulos por columna, ordénalos de mayor a menor y propone una estrategia razonada para ``deck``, ``age`` y ``embarked`/`embark_town``.

Pista de trabajo: Antes de imputar o eliminar, mira cuánto falta y qué función cumple la variable.

4. Busca filas exactamente duplicadas. ¿Cuántas hay? Explica por qué “fila duplicada” no equivale necesariamente a “pasajero duplicado” en este archivo y por qué no deberías eliminarlas automáticamente.

Pista de trabajo: Comprueba si existe un identificador único de pasajero.

5. Calcula estadísticos descriptivos de ``age`` y ``fare``: media, mediana, desviación estándar, Q1, Q3 e IQR. Compara media y mediana y comenta qué sugieren sobre la forma de cada distribución.

Pista de trabajo: La distancia entre media y mediana puede dar una primera pista de asimetría.

6. Realiza un análisis univariado de ``age`` mediante histograma y curva KDE. Describe centro, dispersión, forma y cualquier precaución por los datos faltantes.

Pista de trabajo: No confundas una forma visual con una prueba formal de normalidad.

7. Analiza ``fare`` con histograma y boxplot. Calcula los límites de outliers mediante la regla $1.5 \cdot \text{IQR}$ y cuenta cuántas observaciones quedan fuera. ¿Los eliminarías? Justifica.

Pista de trabajo: Un outlier no es automáticamente un error.

8. Explora las variables categóricas ``sex`` y ``class`` con tablas de frecuencia y gráficos de barras. ¿Qué grupos dominan el dataset y qué implicación puede tener para las comparaciones?

Pista de trabajo: ``value_counts()`` y proporciones.

9. Calcula la tasa global de supervivencia y represéntala gráficamente. Interpreta la diferencia entre contar supervivientes y calcular una tasa.

Pista de trabajo: La tasa permite comparar grupos de tamaños distintos.

10. Compara la tasa de supervivencia entre mujeres y hombres. Incluye una tabla y un gráfico. Describe la asociación observada sin usar lenguaje causal.

Pista de trabajo: ``groupby()`` o ``pd.crosstab(..., normalize=...)``.

11. Compara la tasa de supervivencia entre primera, segunda y tercera clase. ¿Existe un gradiente visible entre las clases?

Pista de trabajo: Ordena las clases de forma lógica para facilitar la lectura.

12. Compara la distribución de `age` entre quienes sobrevivieron y quienes no mediante boxplot o violín. Calcula también la mediana por grupo. ¿La edad parece separar claramente a ambos grupos?

Pista de trabajo: Mira la superposición de las distribuciones, no solo las medianas.

13. Construye una matriz de correlación para las variables numéricas y un heatmap. Identifica las relaciones lineales más relevantes con `survived` y explica por qué correlación no implica causalidad.

Pista de trabajo: No incluyas variables categóricas codificadas como texto sin una transformación justificada.

14. Audita columnas potencialmente redundantes o derivadas: compara `survived` con `alive`, `pclass` con `class`, `embarked` con `embark\_town`, y reflexiona sobre `who`, `adult\_male` y `alone`. ¿Qué riesgo habría al usar columnas que repiten o derivan información en un modelo?

Pista de trabajo: Busca correspondencias uno-a-uno y variables construidas a partir de otras.

15. Realiza un análisis multivariado de supervivencia combinando al menos `sex` y `class`. Cierra el EDA con tres hallazgos, dos hipótesis para un análisis confirmatorio y dos limitaciones del dataset.

Pista de trabajo: Una tabla pivote o barras agrupadas permiten comparar simultáneamente sexo, clase y supervivencia.

16. Crea una variable `family\_size = sibsp + parch + 1`. Analiza su distribución y comprueba si es coherente con la variable `alone`. ¿Encuentras contradicciones entre ambas?

Pista de trabajo: Una persona con `family\_size = 1` debería corresponder a `alone = True` si ambas variables son consistentes.

17. Compara la tasa de supervivencia según `family\_size` y según `alone`. ¿La relación parece lineal? Identifica grupos con tasas altas o bajas y revisa el tamaño de cada grupo antes de interpretar.

Pista de trabajo: No compares solo porcentajes: acompáñalos con el número de observaciones de cada grupo.

18. Agrupa `age` en intervalos razonables (por ejemplo, niñez, adolescencia, adulto joven, adulto y adulto mayor) y compara la supervivencia entre grupos. Explica qué información se gana y qué información se pierde al discretizar una variable continua.

Pista de trabajo: Los límites de los intervalos son una decisión analítica y deben documentarse.

19. Compara la distribución de `fare` entre las clases del Titanic con boxplots y estadísticas por grupo. ¿Qué relación existe entre tarifa y clase, y por qué esto obliga a ser cuidadoso al interpretar la asociación entre `fare` y `survived`?

Pista de trabajo: Busca una posible variable de confusión: clase, tarifa y supervivencia están relacionadas entre sí.

20. Explora `embark\_town` de forma bivariada y multivariada: calcula la supervivencia por puerto y examina cómo se distribuyen las clases dentro de cada puerto. ¿Las diferencias de supervivencia por puerto podrían estar mezcladas con la composición por clase?

Pista de trabajo: Usa una tabla de contingencia normalizada por fila para comparar la composición de clases de cada puerto.

21. Investiga si los valores faltantes parecen distribuirse al azar. Crea indicadores de ausencia para ``age`` y ``deck`` y compara sus porcentajes por ``class`` y por ``survived``. ¿Qué patrón observas?

Pista de trabajo: Si la ausencia cambia mucho entre grupos, imputar ignorando ese patrón puede distorsionar el análisis.

22. Compara dos reglas para detectar valores extremos en ``fare``: $1.5 \cdot \text{IQR}$ y $|z| > 3$. ¿Cuántos casos identifica cada método? ¿Coinciden completamente? Explica por qué dos métodos pueden producir resultados distintos.

Pista de trabajo: La puntuación z depende de media y desviación estándar; IQR usa medidas robustas.

23. Construye una tabla de contingencia normalizada entre ``sex`` y ``class``. ¿La composición por clase es igual para mujeres y hombres? Explica por qué esta diferencia es relevante antes de comparar tasas de supervivencia por sexo.

Pista de trabajo: Una variable puede estar asociada con otra variable que también se relaciona con el resultado.

24. Construye un ``pairplot`` o una matriz de dispersión con ``age``, ``fare``, ``sibsp``, ``parch`` y ``survived``. Describe al menos tres patrones, superposiciones o relaciones que no serían evidentes mirando solo una correlación.

Pista de trabajo: Observa simultáneamente formas de distribución, relaciones entre pares y separación —o falta de separación— entre supervivientes y no supervivientes.

25. Elabora un “registro de decisiones” del EDA: para ``age``, ``deck``, ``embarked``, ``alive``, ``class`` y los duplicados aparentes, indica si conservarías, transformarías, imputarías, eliminarías o investigarías más antes de modelar. Justifica cada decisión y cierra con tres hallazgos, dos hipótesis y dos limitaciones.

Pista de trabajo: No existe una limpieza universalmente correcta; la respuesta debe conectar cada decisión con la pregunta analítica y el riesgo de pérdida o fuga de información.