

Práctica EDA 2: Auto MPG

Cuestionario — 25 ejercicios

1. Carga `auto_mpg.csv` y realiza el primer contacto con el dataset. Reporta dimensiones, primeras filas, tipos de datos y define qué representa una fila.

Pista de trabajo: ``shape``, ``head()``, ``info()`` y ``dtypes``.

2. Clasifica ``mpg``, ``cylinders``, ``displacement``, ``horsepower``, ``weight``, ``acceleration``, ``model_year``, ``origin`` y ``name``. Identifica qué variables, aunque puedan verse numéricas, conviene tratar como categorías o variables temporales.

Pista de trabajo: El significado de una variable es más importante que su dtype.

3. Analiza valores faltantes y duplicados exactos. ¿En qué variable faltan datos y qué proporción representan?

Pista de trabajo: Para una correlación puntual puedes trabajar con pares completos sin alterar toda la tabla.

4. Estudia la cardinalidad de ``name``. ¿Cuántos nombres distintos hay? ¿Que un nombre aparezca varias veces significa que las filas son duplicadas? Compruébalo con ejemplos.

Pista de trabajo: Un mismo modelo de automóvil puede aparecer en años o configuraciones diferentes.

5. Calcula estadísticos descriptivos de ``mpg``, ``weight`` y ``horsepower``: media, mediana, desviación estándar, cuartiles e IQR. Interpreta qué te dicen sobre un automóvil “típico” y sobre la dispersión.

Pista de trabajo: Compara medidas sensibles y robustas frente a valores extremos.

6. Analiza la distribución de ``mpg`` con histograma y KDE.

7. Analiza ``weight`` con histograma y boxplot. ¿La distribución es simétrica? ¿Hay valores extremos según la regla del IQR? Documenta el cálculo.

Pista de trabajo: Calcula Q1, Q3, IQR y límites inferior/superior.

8. Detecta outliers en ``horsepower`` usando $1.5 \cdot \text{IQR}$. Lista los vehículos identificados y comenta si parecen errores evidentes o automóviles de alta potencia plausibles.

Pista de trabajo: Conserva el nombre del vehículo para interpretar el contexto del outlier.

9. Explora ``cylinders`` y ``origin`` mediante frecuencias y gráficos de barras. ¿Qué categorías dominan el dataset? ¿Hay categorías con muy pocos casos?

Pista de trabajo: Las categorías poco frecuentes pueden hacer inestables algunas comparaciones.

10. Compara ``mpg`` entre vehículos con distinto número de cilindros mediante boxplot y medias/medianas por grupo. ¿Qué patrón general observas?

Pista de trabajo: Ordena los cilindros numéricamente.

11. Compara ``mpg`` entre los tres orígenes del dataset. Usa boxplot y estadísticas por grupo.

Pista de trabajo: Las diferencias de origen pueden estar mezcladas con peso, cilindrada, año y otras variables.

12. Estudia la relación entre ``weight`` y ``mpg`` con un scatterplot y la correlación.

13. Estudia la relación entre ``horsepower`` y ``mpg`` con scatterplot y correlación. Compara su intensidad con la relación ``weight`-`mpg``.

Pista de trabajo: Trabaja con las filas donde ``horsepower`` no es nulo.

14. Construye una matriz de correlación y heatmap de las variables numéricas. Identifica las tres variables con mayor asociación lineal absoluta con `mpg` y comenta posibles redundancias entre predictores.

Pista de trabajo: La matriz es simétrica; no hace falta interpretar dos veces cada pareja.

15. Realiza un análisis multivariado de `weight` frente a `mpg` incorporando `origin` y `cylinders` (mediante color, estilo, facetas u otra codificación). Añade la evolución media de `mpg` por `model\_year`.

Pista de trabajo: Busca si el patrón peso–consumo se mantiene dentro de distintos grupos y cómo cambia con el tiempo.

16. Analiza la evolución de `mpg` por `model\_year`. Calcula media y mediana por año y represéntalas en una gráfica de líneas.

Pista de trabajo: Trata `model\_year` como una variable temporal discreta y revisa todos los años, no solo el primero y el último.

17. Compara el `weight` de los automóviles por `origin` mediante estadísticas y boxplots. ¿Puede la diferencia de peso ayudar a explicar parte de las diferencias de `mpg` observadas entre orígenes?

Pista de trabajo: Relaciona este resultado con la fuerte asociación entre peso y consumo observada previamente.

18. Estudia el patrón de los valores faltantes de `horsepower`. Compara su frecuencia por `origin`, `cylinders` y `model\_year`.

Pista de trabajo: Con pocos casos faltantes conviene describir el patrón, pero evitar conclusiones fuertes.

19. Analiza la relación entre `acceleration` y `mpg` mediante scatterplot y correlación de Pearson. Compara su fuerza con las relaciones de `weight` y `horsepower` con `mpg`.

Pista de trabajo: Una correlación moderada puede aportar información, pero no necesariamente domina el comportamiento del objetivo.

20. Explora las relaciones entre `displacement`, `horsepower` y `weight`. Calcula sus correlaciones y crea gráficos de dispersión. ¿Qué problema podría aparecer si se usan simultáneamente como predictores sin revisar redundancias?

Pista de trabajo: Correlaciones muy altas entre predictores son una señal de posible multicolinealidad o redundancia.

21. Construye una tabla pivote con el `mpg` medio por `cylinders` y `origin`, incluyendo el número de automóviles por grupo. ¿El patrón de cilindros se mantiene dentro de cada origen? Señala grupos con muestras pequeñas.

Pista de trabajo: No interpretes con la misma confianza una media basada en 3 automóviles que otra basada en más de 60.

22. Compara la evolución temporal de `mpg` entre `origin` usando líneas por grupo. ¿Los tres orígenes mejoran con el tiempo? ¿La brecha entre orígenes permanece constante?

Pista de trabajo: Una gráfica con `model\_year` en x, `mpg` medio en y y una línea por origen permite ver interacción entre tiempo y origen.

23. Compara los outliers de `horsepower` detectados mediante $1.5 \cdot \text{IQR}$ y mediante $|z| > 3$. Lista los vehículos más extremos y explica por qué un método puede ser más estricto que el otro en una distribución asimétrica.

Pista de trabajo: Comprueba la intersección entre ambos conjuntos de outliers en lugar de asumir que producen la misma lista.

24. Construye un `pairplot` con `mpg`, `weight`, `horsepower`, `displacement` y `model\_year`, usando `origin` como color.

25. Elabora un “registro de decisiones” para preparar un análisis posterior: decide qué harías con los nulos de `horsepower`, `name`, `origin`, los outliers de potencia y las variables altamente correlacionadas.

Pista de trabajo: Distingue entre decisiones para EDA y decisiones para modelado; una variable útil para interpretar puede no ser adecuada como predictor directo.