

PRÁCTICA DE PANDAS

Dataset: Palmer Penguins · Python / Pandas

Dataset de trabajo

Palmer Penguins es un dataset pequeño y apropiado para practicar limpieza, filtros, agregaciones y transformaciones con Pandas. El archivo usado en esta práctica contiene 344 registros y 8 columnas.

CSV directo: <https://raw.githubusercontent.com/allisonhorst/palmerpenguins/main/inst/extdata/penguins.csv>

Repositorio del proyecto: <https://github.com/allisonhorst/palmerpenguins>

Código base recomendado:

```
import pandas as pd

url = "https://raw.githubusercontent.com/allisonhorst/palmerpenguins/main/inst/extdata/penguins.csv"
df = pd.read_csv(url)
```

NIVEL 1 — BÁSICO

Exploración y selección

1. Carga del dataset

Carga el archivo penguins.csv utilizando Pandas y almacénalo en un DataFrame llamado df.

2. Primeros registros

Muestra las primeras 5 filas del dataset.

3. Últimos registros

Muestra las últimas 8 filas del dataset.

4. Dimensiones

Determina el número de filas y el número de columnas del DataFrame.

5. Columnas

Obtén una lista con los nombres de todas las columnas del DataFrame.

6. Tipos de datos

Muestra el tipo de dato (dtype) de cada columna.

7. Información general

Utiliza una función de Pandas que permita visualizar las columnas, la cantidad de valores no nulos, los tipos de datos y la memoria utilizada.

8. Estadísticas descriptivas

Obtén las estadísticas descriptivas de todas las columnas numéricas.

9. Selección de columnas

Crea un nuevo DataFrame llamado penguins_mass que contenga únicamente las columnas species, island y body_mass_g.

10. Valores únicos

Determina cuáles son las especies diferentes existentes en `species` y cuántas especies distintas existen.

NIVEL 2 — BÁSICO / INTERMEDIO

Filtros, ordenamiento y valores faltantes

11. Conteo por especie

Cuenta cuántos pingüinos existen de cada especie.

12. Conteo por isla

Determina cuántos pingüinos fueron registrados en cada isla.

13. Filtro simple

Obtén todos los pingüinos cuya masa corporal sea superior a 5000 gramos.

14. Filtro por categoría

Obtén únicamente los pingüinos de especie Gentoo.

15. Múltiples condiciones

Obtén los pingüinos que cumplan simultáneamente: `species == "Gentoo"` y `body_mass_g > 5000`.

16. Condición OR

Obtén los registros correspondientes a pingüinos de las especies Adelie o Chinstrap. Intenta resolverlo sin crear dos DataFrames separados.

17. Ordenamiento

Ordena el dataset de mayor a menor utilizando `body_mass_g`.

18. Top 10

Encuentra los 10 pingüinos con mayor masa corporal. Muestra solamente `species`, `island`, `sex` y `body_mass_g`.

19. Valores nulos

Determina cuántos valores faltantes existen en cada columna.

20. Eliminar valores faltantes

Crea un DataFrame llamado `df_clean` que elimine únicamente los registros que tengan valores faltantes en `sex` o `body_mass_g`. Comprueba cuántas filas fueron eliminadas.

NIVEL 3 — INTERMEDIO

Transformaciones, GroupBy y agregaciones

21. Crear una nueva columna

Crea una columna llamada `body_mass_kg` con la masa corporal expresada en kilogramos. Recuerda: 1000 g = 1 kg. No modifiques `body_mass_g`.

22. Clasificación mediante `pd.cut()`

Crea una nueva columna `mass_category` clasificando los pingüinos como `Light` si pesan menos de 3500 g, `Medium` si pesan entre 3500 y 4500 g (inclusive) y `Heavy` si pesan más de 4500 g. Utiliza `pd.cut()`.

23. Masa promedio por especie

Calcula la masa corporal promedio (`body_mass_g`) de cada especie. El resultado debe tener una fila por especie.

24. Múltiples estadísticas

Para cada especie calcula sobre `body_mass_g`: cantidad, promedio, mínimo, máximo y desviación estándar. Intenta resolverlo utilizando `groupby()` y `agg()`.

25. Agrupación utilizando dos columnas

Calcula la masa corporal promedio agrupando por `species` y `sex`. El resultado debe permitir comparar machos y hembras dentro de cada especie.

26. Tabla cruzada

Construye una tabla que muestre cuántos pingüinos existen para cada combinación `species × island`. Puedes utilizar `pd.crosstab()` o `pivot_table()`.

27. Pingüino más pesado de cada especie

Encuentra el registro correspondiente al pingüino con mayor `body_mass_g` dentro de cada especie. El resultado final debe mostrar `species`, `sex`, `island` y `body_mass_g`. No basta con mostrar únicamente la masa máxima: debes recuperar el registro completo correspondiente al máximo.

28. Diferencia respecto al promedio

Crea una columna `mass_difference` que indique cuánto pesa cada pingüino por encima o por debajo del promedio de su propia especie. Conceptualmente: `masa del pingüino - masa promedio de su especie`. Intenta resolverlo usando `groupby()` y `transform()`.

29. Ranking dentro de cada especie

Crea una columna `mass_rank` que indique el ranking de masa corporal de cada pingüino dentro de su propia especie. El pingüino más pesado debe tener `mass_rank = 1`. Luego muestra los 3 pingüinos más pesados de cada especie.

EJERCICIO INTEGRADOR

Aplicación de varias operaciones de Pandas

30. Ejercicio integrador — Reporte de especies

Construye un DataFrame llamado `species_report` con una fila por especie y las columnas: `species`, `total_penguins`, `average_body_mass`, `min_body_mass`, `max_body_mass`, `average_flipper_length` y `average_bill_length`. Redondea los promedios a 2 decimales. Luego ordénalo de mayor a menor por `average_body_mass`, identifica la especie con mayor masa promedio y la especie con mayor longitud promedio de aleta, y guarda el resultado en `species_report.csv` sin incluir el índice.

Resumen de la práctica

Nivel	Preguntas	Conceptos principales
Básico	1–10	Carga, exploración, selección, estadísticas
Básico / Intermedio	11–20	Filtros, condiciones, ordenamiento, nulos
Intermedio	21–29	Nuevas columnas, groupby, agg, crosstab, transform, rank
Integrador	30	Transformación, agregación, análisis y exportación